### DORISMOND Samuel, BUT3 Info FA - Farore

SAÉ 5.A.01 - Rapport sur le travail réalisé n°1

Analyse et Entraînement du Modèle GPT-2 | 04/12/2023 - 18/12/2023

Durant cette phase du projet, j'ai eu pour mission principale l'analyse de mots du dataset en collaboration avec Aurélien, suivie par le fine-tuning et l'entraînement du modèle GPT-2. Mon travail a consisté à comprendre en profondeur les spécificités et le potentiel de GPT-2 en contexte d'analyse de données textuelles.

### Analyse de Mots du Dataset

J'ai débuté par l'analyse de mots du dataset, en collaboration avec Aurélien. Notre approche a consisté à identifier les mots-clés, les fréquences et les schémas d'utilisation des mots dans le dataset. Nous avons utilisé des outils d'analyse textuelle avancée pour dégager des insights pertinents, ce qui nous a permis de mieux comprendre la nature des données avec lesquelles nous travaillions.

## Fine-Tuning et Entraînement du Modèle GPT-2

Par la suite, j'ai entamé le processus de fine-tuning et d'entraînement du modèle GPT-2. Cette étape a été cruciale pour adapter le modèle à nos besoins spécifiques. J'ai commencé par ajuster les paramètres du modèle pour optimiser ses performances sur notre dataset. J'ai ensuite procédé à des séances d'entraînement intensives, en utilisant Jupyter Notebook pour tester et affiner le modèle.

## Expériences et Observations

Tout au long de cette phase, j'ai effectué divers tests pour évaluer la capacité du modèle à générer des textes cohérents et pertinents. J'ai noté plusieurs aspects intéressants du modèle, notamment sa capacité à apprendre de manière efficace de notre dataset spécifique. Cependant, j'ai également observé certains défis, tels que la gestion des nuances dans les données textuelles et la nécessité d'un entraînement ciblé pour obtenir des résultats optimaux.

# Conclusion et Perspectives

En conclusion, cette phase du projet a été extrêmement enrichissante. Elle m'a permis de développer mes compétences en matière d'analyse de données textuelles et de

manipulation de modèles de traitement du langage naturel. Le travail réalisé jette les bases pour des explorations plus approfondies et ouvre la voie à des applications plus complexes du modèle GPT-2 dans notre projet.